Práctica Final: Regresión lineal y correlación

Probabilidad y Estadística con Python - Unidad 5

Docente: Dr. José Gabriel Rodríguez Rivas

Alumno: Zaid Emilio Ortiz Amparan

Resumen de resultados

Cada grupo tiene n = 50 estudiantes (horas de estudio entre 3.79 y 20; media de 14.35 h en los tres). Variable independiente (X): horas de estudio. Variable dependiente (Y): calificación final. Nivel de significancia: $\alpha = 0.05$.

	Grupo 1	Grupo 2	Grupo 3
Intercepto	85.3107	15.3075	0.1081
Pendiente	-0.1061	4.2227	5.2857
Pearson (r)	-0.0571	0.8620	0.9422
R^2	0.0033	0.7430	0.8878
Valor p	0.6935	9.08e-16	1.93e-24
Error estándar del modelo	7.90 pts	10.59 pts	8.01 pts
Calificación media	83.79	75.91	75.97

Grupo 1

Calificación = 85.3107 - 0.1061 x Horas de estudio

1. ¿Cuál es la interpretación del coeficiente de regresión en términos de la relación entre el tiempo de estudio y las calificaciones finales?

La pendiente es -0.1061: por cada hora adicional de estudio, la calificación final cambiaría en promedio -0.11 puntos, es decir, prácticamente cero. El intercepto (85.31) indica que la calificación promedio ronda los 85 puntos sin importar las horas. Además, el intervalo de confianza al 95% de la pendiente (de -0.64 a 0.43) incluye al cero, por lo que no hay evidencia de que estudiar más o menos modifique la calificación en este grupo.

2. ¿Cómo se interpreta el coeficiente de correlación en términos de la fuerza y dirección de la relación entre las variables?

r = -0.0571 es un valor muy cercano a 0: la relación lineal es **nula (inexistente)**. El signo negativo es tan pequeño que no representa una dirección real, solo ruido. El diagrama de dispersión lo confirma: los puntos forman una nube sin tendencia y la línea de regresión es casi horizontal. Las calificaciones se mantienen alrededor de 83-85 sin importar si el estudiante estudió 7 o 20 horas.

3. ¿El modelo de regresión lineal es estadísticamente significativo?

No. El valor p = 0.6935 es mucho mayor que 0.05, por lo que no se rechaza la hipótesis nula (pendiente = 0). Con R^2 = 0.0033, las horas de estudio explican apenas el 0.33% de la variación de las calificaciones; el 99.7% restante se debe a otros factores.

4. ¿Qué tan confiable es el modelo de regresión para predecir las calificaciones finales de los estudiantes basado en el tiempo de estudio?

Nada confiable. Como no hay relación lineal, el modelo no aporta información útil: predecir con la línea de regresión es prácticamente igual a predecir con el promedio del grupo (alrededor de 84). El error típico de predicción es de unos 7.9 puntos, casi igual a la desviación estándar de las calificaciones (7.83), es decir, el modelo no mejora nada. No debe usarse para predecir.

Grupo 2

Calificación = 15.3075 + 4.2227 x Horas de estudio

1. ¿Cuál es la interpretación del coeficiente de regresión en términos de la relación entre el tiempo de estudio y las calificaciones finales?

La pendiente es 4.2227: por cada hora adicional de estudio, la calificación final aumenta en promedio 4.22 puntos. El intervalo de confianza al 95% de la pendiente es de 3.50 a 4.94, siempre positivo, por lo que el efecto es real y no se debe al azar. El intercepto (15.31) es la calificación teórica con 0 horas de estudio; es un valor de referencia matemático, ya que ningún estudiante del grupo estudió menos de 3.79 horas.

2. ¿Cómo se interpreta el coeficiente de correlación en términos de la fuerza y dirección de la relación entre las variables?

r = 0.8620 indica una correlación **positiva y fuerte**: a más horas de estudio, mayor calificación. El coeficiente de determinación R^2 = 0.7430 significa que el 74.3% de la variabilidad de las calificaciones se explica por las horas de estudio. En el diagrama de dispersión los puntos siguen claramente la línea ascendente, aunque con cierta dispersión, sobre todo en los extremos.

3. ¿El modelo de regresión lineal es estadísticamente significativo?

Sí. El valor p = 9.08×10^{-16} es muchísimo menor que 0.05 (estadístico t = 11.78), por lo que se rechaza que la pendiente sea cero. Existe evidencia estadística muy fuerte de una relación lineal entre horas de estudio y calificación.

4. ¿Qué tan confiable es el modelo de regresión para predecir las calificaciones finales de los estudiantes basado en el tiempo de estudio?

Razonablemente confiable, con reservas. El modelo explica el 74% de la variación, pero el error típico de predicción es de unos 10.6 puntos, lo cual es considerable para una escala de 0 a 100. Además, los datos muestran que la relación se aplana arriba de 15-16 horas (las calificaciones se acercan al máximo, de 90 a 99), por lo que una línea recta describe mejor la zona media. Sirve para estimar tendencias generales, pero no para predecir con precisión la calificación de un estudiante individual.

Grupo 3

Calificación = 0.1081 + 5.2857 x Horas de estudio

1. ¿Cuál es la interpretación del coeficiente de regresión en términos de la relación entre el tiempo de estudio y las calificaciones finales?

La pendiente es 5.2857: por cada hora adicional de estudio, la calificación final aumenta en promedio 5.29 puntos, el mayor efecto de los tres grupos. El intervalo de confianza al 95% va de 4.74 a 5.83 (siempre positivo), lo que indica una estimación precisa. El intercepto (0.11) es casi cero: con 0 horas de estudio, la calificación esperada sería prácticamente 0.

2. ¿Cómo se interpreta el coeficiente de correlación en términos de la fuerza y dirección de la relación entre las variables?

r = 0.9422 indica una correlación **positiva y muy fuerte**, casi lineal perfecta. El R^2 = 0.8878 significa que el 88.8% de la variación en las calificaciones se explica por las horas de estudio. En el diagrama de dispersión los puntos se alinean muy cerca de la recta ascendente, con poca dispersión.

3. ¿El modelo de regresión lineal es estadísticamente significativo?

Sí. El valor p = 1.93×10^{-24} es prácticamente cero (estadístico t = 19.49), muy por debajo de 0.05. El modelo es altamente significativo y se rechaza con total seguridad que la pendiente sea cero.

4. ¿Qué tan confiable es el modelo de regresión para predecir las calificaciones finales de los estudiantes basado en el tiempo de estudio?

Muy confiable dentro del rango observado (aprox. 4 a 17 horas), ya que explica casi el 89% de la variación y el error típico es de unos 8 puntos. Sin embargo, tiene un límite: la escala de calificaciones llega a 100 y las notas se estabilizan alrededor de 95-99 a partir de unas 17 horas, de modo que la recta no debe extrapolarse (por ejemplo, para 20 horas predice 105.8, un valor imposible). Es un buen modelo para predecir en el rango de datos, pero no más allá de él.

Conclusiones generales

Los tres grupos tienen el mismo rango de horas de estudio (3.79 a 20 h, media de 14.35 h) y, sin embargo, arrojan resultados muy distintos, lo cual muestra que la relación entre estudio y rendimiento depende de los datos de cada grupo.

Grupo 1: no existe relación lineal ($r = -0.06$, $p = 0.69$, $R^2 = 0.003$). Las calificaciones se mantienen cerca de 84 puntos sin importar el tiempo de estudio, y el modelo no sirve para predecir. Es un ejemplo de que "estudiar más horas" no garantiza una mejor calificación cuando intervienen otros factores (calidad del estudio, conocimientos previos, método de evaluación, etc.).

Grupo 2: existe una relación lineal positiva y fuerte ($r = 0.86$, $R^2 = 0.74$, $p < 0.001$). Cada hora extra de estudio se asocia con unos 4.2 puntos más. El modelo es útil para ver la tendencia general, pero su error de predicción (10.6 puntos) es el mayor de los tres.

Grupo 3: presenta la relación más fuerte ($r = 0.94$, $R^2 = 0.89$, $p < 0.001$), con una ganancia de unos 5.3 puntos por hora y el mejor ajuste de los tres. Aun así, el modelo solo es válido dentro del rango de horas observado, porque las calificaciones tienen un tope de 100.

Observaciones finales: (1) un modelo estadísticamente significativo no siempre es bueno para predecir, por lo que conviene revisar también R^2 y el error típico; (2) la correlación no implica causalidad: aunque en los grupos 2 y 3 más horas se asocian con mejores calificaciones, los datos por sí solos no demuestran que las horas sean la causa; (3) la regresión lineal no debe usarse fuera del rango de los datos; y (4) en conjunto, se concluye que **el tiempo de estudio sí está relacionado linealmente con el rendimiento académico en los grupos 2 y 3, pero no en el grupo 1**.